

基于视觉-文本双模态融合的直播场景情感识别系统实验报告

实验者：王文淼2024141450140 任晨曦2024141450142 王浩然2024141450146
李奕奋 2024141450123 张哲睿2024141450113

2026 年 6 月 21 日

摘要

本实验搭建并实现视觉-文本双模态融合的直播场景情感识别系统，面向直播主播表情与弹幕、字幕开展多模态情感分析。视觉分支采用 YuNet 轻量化人脸检测器定位主播面部区域，基于 ResNet18 构建 EmotionResNet 模型完成七类基础表情识别（开心、悲伤、愤怒、恐惧、厌恶、惊讶、中性）；文本分支通过 EasyOCR 提取视频内字幕、弹幕文本，结合自研 EnhancedOfflineBERT 模型实现正向、负向、中性三分类情感识别。融合模块设计基于单分支置信度的动态加权晚期融合策略，将文本三分类结果映射至七维情绪空间，与视觉情绪概率向量加权融合输出最终情感。实验针对单模态缺陷、多模态互补性、表情与文本情感矛盾样本开展专项测试与分析。系统前端基于 Gradio 搭建轻量级 Web 交互界面，支持视频上传、实时推理流式显示与结果可视化。结果表明：多模态融合有效弥补单一模态受环境、语义干扰的短板，系统鲁棒性与识别准确率显著提升，可有效适配直播复杂场景下的情感识别需求。

1 实验目的

- 完成视觉单模态情感识别：实现视频流中主播人脸实时检测、面部表情七分类，分析光照、人脸姿态、遮挡对视觉识别效果的影响。
- 完成文本单模态情感识别：通过 OCR 提取直播字幕、弹幕文本，实现文本情感三分类，分析网络用语、短句、口语化表达对文本识别的干扰。
- 实现多模态晚期融合算法：设计动态加权融合规则，完成文本、视觉模态特征融合，输出统一情感结果。
- 对比分析单模态与多模态模型性能差异，验证多模态信息互补的优势。
- 针对表情-文本情感矛盾样本进行专项分析，测试动态融合策略在冲突场景下的决策能力。
- 基于完整工程代码实现系统落地，完成视频流实时推理、可视化展示等功能，验证系统工程实用性。
- 构建友好的人机交互前端界面，支持视频上传、一键启动分析、实时画面刷新与结果展示，降低非专业用户使用门槛。

2 实验环境与软硬件配置

2.1 硬件环境

- 运行设备：PC 台式机

- 处理器：主流 x86 架构 CPU
- 显卡：支持 CUDA 的 NVIDIA 显卡（可选，代码自动兼容 CPU/GPU 双模式推理）
- 存储：本地路径存储模型权重、YuNet 人脸检测 ONNX 模型、测试视频文件

2.2 软件环境

- 操作系统：Windows 10/11
- 编程语言：Python 3.8+
- 核心依赖库：
 - 计算机视觉：OpenCV-python（人脸检测、视频解码、画面绘制）、PIL（中文文字渲染）
 - 深度学习框架：PyTorch（模型训练、推理、张量计算）、torchvision（ResNet 网络、图像预处理）
 - 文本识别：EasyOCR（文字提取，本地离线运行）
 - 前端交互：Gradio（Web 界面搭建、视频流式输出）
 - 辅助工具：re（文本清洗）、numpy（数值计算）

2.3 文件路径配置（代码对应）

所有模型、视频、OCR 模型均部署于本地 E:\python\project1 目录，全程离线运行，无网络依赖：

- YuNet 人脸检测模型：E:\python\project1\face_detection_yunet_2023mar.onnx
- 文本情感模型权重：E:\python\project1\best_danmu_model_v1.pth
- 视觉表情模型权重：E:\python\project1\best_emotion_model.pth
- EasyOCR 本地模型：E:\python\project1（关闭自动下载，纯离线识别）

3 系统总体架构与工作流程

3.1 整体架构

系统采用流水线式模块化设计，共分为 7 大功能模块（含前端交互），模块间低耦合、独立运行：

前端界面（Gradio）→ 视频输入模块 → 分支 1（人脸检测 + 视觉情感识别）、分支 2（OCR 文本提取 + 文本情感识别）→ 多模态融合决策模块 → 结果可视化与输出模块 → 前端实时画面刷新

核心功能模块拆解（结合代码类结构）：

- 前端交互模块（app.py）：基于 Gradio 构建 Web 界面，提供视频上传控件、启动按钮和实时画面显示区域，通过生成器函数与后端视频处理流水线对接。
- 视频解码模块：基于 cv2.VideoCapture 读取本地视频流，逐帧输出图像数据。

- **OCR 模块（SyncOCR）**：同步提取字幕、弹幕文本，做文本清洗后输出纯文本内容。
- **人脸检测模块（YuNetFaceDetector）**：基于 YuNet ONNX 模型检测视频指定 ROI 区域内人脸，无 YuNet 时自动降级为 Haar 级联检测。
- **视觉情感识别模块（EmotionResNet）**：对截取人脸灰度图做预处理，完成七类表情概率预测。
- **文本情感识别模块（EnhancedOfflineBERT + EnhancedTokenizer）**：字符级分词、编码，完成文本三分类情感预测。
- **多模态融合模块（MultiModalEmotionFusion）**：模态维度映射、动态加权融合、最终情感决策。
- **可视化与结果渲染模块**：绘制人脸框、识别区域、中文结果，将标注后的帧返回前端展示。

3.2 核心工作流程

1. 用户通过 Gradio 前端界面上传视频文件，点击“开始实时分析”按钮。
2. 后端接收视频路径，初始化所有模型和 OCR 工具，进入逐帧处理循环。
3. 视频逐帧读取，图像同时送入人脸检测与 OCR 处理。
4. OCR 模块处理画面，分底部字幕区域、右侧弹幕区域提取文本并清洗；主线程定时检测人脸区域，截取人脸 ROI 图像。
5. 文本、视觉数据分别送入对应模型，输出情感概率与单分支置信度。
6. 融合模块将文本三分类结果映射为七维情绪向量，结合双方置信度动态计算权重，加权融合得到最终情感标签。
7. 将人脸框、识别区域、原始文本、单模态结果、融合结果绘制在视频画面中。
8. 标注后的帧通过生成器逐次返回给前端，前端实时更新显示画面，形成流式播放效果。
9. 循环执行直至视频播放结束或用户手动停止。

3.3 ROI 区域划分（代码固定区域策略）

为提升识别效率、减少无效计算，对视频画面做固定比例区域划分：

- **字幕区域**：画面纵向 70%至100%，横向 0 至 100%（视频底部区域）
- **弹幕区域**：画面横向 70% 至 100%，纵向 0 至 70%（视频右侧区域）
- **主播人脸区域**：画面全屏整块区域

4 核心任务一：视觉情感识别（主播表情识别）

4.1 技术方案选型

视觉任务分为人脸检测和表情分类两个子任务：

4.1.1 人脸检测：YuNet

选用 OpenCV 官方开源 YuNet 轻量化人脸检测模型（ONNX 格式），优势为体积小、速度快、适配视频实时流。代码中设置：置信度阈值 0.6、NMS 阈值 0.3，仅保留高置信度人脸。

容错机制：若 YuNet 模型缺失/加载失败，自动降级为 OpenCV 内置 Haar 级联人脸检测器，保证系统不中断。

优化策略：加入帧缓存降频机制，连续帧不重复检测人脸，降低 CPU 算力消耗。

4.1.2 表情分类：EmotionResNet（基于 ResNet18）

以经典轻量卷积网络 ResNet18 为骨干网络，针对表情任务做定制修改：

- **输入适配：**原 ResNet18 接收 RGB 三通道图像，本任务改为单通道灰度图，修改首层卷积 conv1 输入通道为 1
- **输出适配：**将原 ImageNet 千分类全连接层，替换为 7 维输出全连接层，对应 7 类表情
- **后处理：**模型输出 Logits 经 Softmax 归一化为概率向量，取最大概率为预测表情，最大值为该分支视觉置信度

4.2 图像预处理流程（代码对应 transforms）

截取人脸区域图像后执行标准化预处理：

- **缩放：**统一尺寸至 48×48
- **灰度化：**转为单通道图像
- **张量转换：**PIL 图像转为 PyTorch 张量
- **归一化：**均值 0.5、标准差 0.5，完成数据标准化

4.3 识别类别

七类表情标签：Angry（愤怒）、Disgust（厌恶）、Fear（恐惧）、Happy（开心）、Sad（悲伤）、Surprise（惊讶）、Neutral（中性）。

4.4 单模态视觉缺陷分析（结合实验现象 + 代码逻辑）

- **环境干扰：**直播画面光照不均、反光、逆光会大幅降低人脸特征质量，导致置信度下降
- **姿态与遮挡：**主播侧脸、低头、手部遮挡面部时，人脸检测漏检/误检，表情识别失效
- **帧率限制：**高频切换的表情易被帧缓存机制跳过，造成识别滞后

5 核心任务二：文本情感识别（字幕 + 弹幕识别）

5.1 技术方案选型

文本任务分为文本提取、分词编码、情感分类三部分，全程离线运行，无网络请求。

5.1.1 文本提取：EasyOCR

采用 EasyOCR 实现离线文字识别。

关键优化（代码实现）：

- 区域裁剪：仅对预设字幕、弹幕 ROI 做识别，减少计算量
- 图像增强：小尺寸文字区域做放大插值，提升小字识别率
- 文本清洗：通过正则表达式过滤标点符号、乱码，输出纯净文本
- 阈值过滤：仅保留置信度 > 0.15 的识别结果，过滤无效字符

5.1.2 文本编码：EnhancedTokenizer

自研字符级分词器，以字符为最小单元构建词表（适配中文无分词特点）：

- 内置占位符：<PAD> 填充符、<UNK> 未知字符
- 词表构建：基于训练语料统计字符频次，按频次排序生成词表
- 固定长度编码：统一文本长度为 32 字符，超长截断、短文本补零

5.1.3 情感分类：EnhancedOfflineBERT

简化版离线 Transformer 编码模型，模拟 BERT 特征提取逻辑，结构如下：

- 嵌入层（Embedding）：字符转稠密向量
- 多层 TransformerEncoder：3 层编码器、4 头注意力机制，提取文本上下文语义
- Dropout 层：抑制过拟合
- 全连接层：输出 3 维 Logits，对应 Positive（正向）、Negative（负向）、Neutral（中性）三类情感

输出经 Softmax 转为概率，最大概率值为文本分支置信度。

5.2 训练语料与编码规则

内置基础训练语料覆盖直播常见短句、网络用语：

- 正向：主播太厉害！、666、太强了、操作好丝滑、牛逼、主播加油等
- 负向：什么垃圾操作、太菜了吧、会不会玩、辣鸡、这都能输等
- 中性：还行吧、一般般、就这样、还行、中规中矩等

5.3 单模态文本缺陷分析

- 语义干扰：直播弹幕存在反讽、谐音、网络黑话，字面语义与真实情感相悖
- OCR 误差：画面模糊、文字倾斜、弹幕重叠导致识别错字、漏字，破坏语义
- 短句歧义：单字、极短弹幕语义模糊，分类置信度偏低

6 核心任务三：多模态融合策略（晚期动态加权融合）

6.1 融合方式选择：晚期融合

本系统采用特征级晚期融合：不融合网络中间特征，分别输出视觉七维概率向量、文本映射后七维概率向量，在决策层完成加权融合。

优势：两个模态模型独立训练、独立推理，解耦性强，单模态故障不导致整体系统崩溃，适配工程落地。

6.2 维度映射规则（代码固定映射矩阵）

文本模型输出为 3 维概率（正/负/中），视觉为 7 维概率（七类表情），首先完成维度对齐，定义映射矩阵 TEXT_TO_7：

Listing 1: TEXT_TO_7 映射矩阵

```
1 TEXT_TO_7 = np.array ([
2     [0.25, 0.25, 0.25, 0.0, 0.25, 0.0, 0.0], # 正向情感 -> 分配至愤怒、厌恶、恐
      惧、悲伤
3     [0.0, 0.0, 0.0, 0.0, 0.0, 0.0, 1.0], # 中性情感 -> 完全对应中性表情
4     [0.0, 0.0, 0.0, 0.5, 0.0, 0.5, 0.0] # 负向情感 -> 分配至开心、惊讶
5 ])
```

计算规则：文本七维概率 = 文本三维概率 × 映射矩阵，实现两模态维度统一。

6.3 动态权重逻辑（代码核心逻辑）

- 当文本 OCR 清晰、语义明确（文本置信度高），自动提升文本分支话语权
- 当人脸完整、表情清晰（视觉置信度高），自动提升视觉分支话语权
- 若某一分支失效（如无人脸/无文本），则另一分支结果直接作为最终结果
- 两分支同时有效时，按置信度自适应加权，平衡双方输出

6.4 融合后决策规则

融合得到七维概率向量后，取最大概率对应的表情标签作为系统最终情感输出，最大概率为整体融合置信度。

7 核心任务四：单模态与多模态性能对比分析

结合实验运行效果与理论分析，从准确率、鲁棒性、抗干扰能力、适用场景四个维度对比：

7.1 单模态视觉模型

- 优势：**主播面部清晰、光照良好时，表情识别直观、准确率高
- 劣势：**受光照、遮挡、姿态影响极大，复杂直播画面下误判率高
- 适用场景：**仅分析主播表情、无弹幕/字幕的纯视频场景

7.2 单模态文本模型

- **优势：**不受画面环境影响，可精准解读弹幕、字幕的文字语义
- **劣势：**无法感知主播真实状态，易被反讽、歧义语句误导，OCR 出错则完全失效
- **适用场景：**仅分析观众评论、无主播画面的纯文本场景

7.3 多模态融合模型

互补性体现：

- 画面质量差、人脸模糊时，自动加大文本权重，依靠文本语义决策
- 文本语义歧义、弹幕杂乱时，自动加大视觉权重，依靠主播表情决策
- 整体表现：平均准确率、场景鲁棒性全面优于任意单模态，可适配直播全场景
- 实验现象：正常场景下融合结果与单模态高置信度结果保持一致；干扰场景下，融合有效降低误判

7.4 量化现象总结

- **模态信息一致**（表情开心 + 弹幕正向）：三者输出结果完全统一，融合置信度高于单模态
- **单一模态低置信**（人脸模糊/文本歧义）：融合结果偏向另一高置信模态，纠正误判
- **双模态低置信**（画面差 + 文本乱）：融合结果偏向中性，避免极端误判

8 核心任务五：矛盾样本专项分析（表情与文本情感冲突）

8.1 典型矛盾场景

直播高频冲突场景：主播面带微笑（视觉识别为 Happy 开心，视觉置信度高），但弹幕大量负面评论（文本识别为 Negative 负向，文本置信度高）。

8.2 单模态表现

- **视觉单模态：**强制输出 Happy（开心），无法感知观众负面情绪，脱离直播整体语境
- **文本单模态：**强制输出对应负向映射表情，忽略主播真实神态，判断片面

8.3 多模态融合表现（结合代码动态权重）

- 两分支置信度均处于较高水平，权重均等参与计算
- 开心概率与负向对应表情概率相互抵消，融合后最大概率偏向 Neutral（中性），整体情感偏向中性偏负面
- 输出结果兼顾主播神态与观众评论，更贴合直播真实语境，避免单模态极端误判

8.4 多组冲突场景实验结论

- 视觉高置信、文本低置信：融合结果偏向主播表情
- 文本高置信、视觉低置信：融合结果偏向弹幕文本情感
- 双方置信度接近：结果收敛为中性，折中输出，符合客观场景

9 关键代码模块解析（结合报告功能对应关系）

本系统代码采用面向对象模块化编程，每个类对应报告中一个核心功能：

- `draw_chinese_text` 函数：解决 `OpenCV` 原生接口无法正常显示中文、出现乱码/问号的问题，基于 `PIL` 实现中文渲染，对应报告结果可视化模块。
- `EnhancedOfflineBERT + EnhancedTokenizer` 类：实现文本编码、语义提取、情感三分类，对应文本情感识别核心任务。
- `EmotionResNet` 类：基于 `ResNet18` 改造的七分类表情模型，对应视觉情感识别核心任务。
- `YuNetFaceDetector` 类：人脸检测主类，集成 `YuNet` 与 `Haar` 双检测器、帧缓存优化，对应人脸定位子任务。
- `MultiModalEmotionFusion` 类：系统核心融合器，整合两大模型、维度映射、动态加权算法，对应多模态融合核心任务。
- `SyncOCR` 类：同步 `OCR`、区域文本提取、文本清洗，对应字幕/弹幕文本提取模块。
- `process_video_stream` 函数：程序主处理流水线，串联所有模块、视频流循环、画面绘制，并以生成器形式逐帧输出标注结果。
- 前端界面（`app.py`）：基于 `Gradio` 搭建，负责文件上传、触发分析、实时显示视频流，实现人机交互。

10 前端交互界面设计与实现

10.1 技术选型与设计目标

前端采用 **Gradio** 框架，它是一个开源的 `Python` 库，能够快速构建机器学习模型的 `Web` 演示界面。选择 `Gradio` 的原因如下：

- 轻量级：无需编写 `HTML/CSS/JavaScript`，纯 `Python` 代码即可构建交互界面。
- 与后端无缝集成：可直接调用 `Python` 函数，支持生成器输出，天然适配视频流式返回。
- 跨平台：生成的 `Web` 页面可在任何现代浏览器中打开，支持局域网访问。
- 快速迭代：开发周期短，适合实验性系统的前端展示。

设计目标是为用户提供简洁直观的操作入口：

- 上传本地视频文件

- 一键启动实时情感分析
- 实时观看带标注结果的视频画面
- 无需任何命令行操作，降低使用门槛

10.2 界面布局与交互流程

前端界面代码位于 app.py，核心布局如下：

```
1 import gradio as gr
2 from main import process_video_stream
3
4 with gr.Blocks(theme=gr.themes.Soft()) as demo:
5     gr.Markdown("# 视频实时情感识别（无音频）")
6     gr.Markdown("上传视频，逐帧实时分析并显示情感标签（无音频输出）")
7     with gr.Row():
8         with gr.Column():
9             input_video = gr.Video(label="上传视频", interactive=True)
10            btn = gr.Button("开始实时分析", variant="primary")
11            with gr.Column():
12                output_image = gr.Image(label="实时画面", type="numpy", height=400)
13                btn.click(fn=process_video_stream, inputs=input_video, outputs=output_image)
14
15 if __name__ == "__main__":
16     demo.launch(share=False, server_name="0.0.0.0", server_port=7860)
```

界面组成：

- 标题区：显示系统名称和简要说明。
- 左列（输入区）：
 - gr.Video 组件：支持拖拽或点击上传视频文件（常见格式如 mp4、avi 等）。
 - gr.Button 按钮：触发分析流程。
- 右列（输出区）：
 - gr.Image 组件：类型为 numpy，以约 400 像素高度实时显示当前处理帧的标注结果。

交互流程：

1. 用户上传视频文件，组件返回视频文件路径。
2. 点击按钮，后端调用 process_video_stream(video_path) 函数。
3. 该函数是一个生成器（yield），逐帧返回处理后的 RGB 图像。
4. Gradio 自动轮询生成器，每当有新帧产出，即更新 output_image 组件，形成流畅的“伪实时”播放效果。
5. 视频播放完毕或用户关闭页面，生成器自动终止，资源释放。

10.3 前后端数据交互机制

后端 main.py 中的 process_video_stream 函数被设计为生成器，这是实现流式输出的关键：

```
1 def process_video_stream (video_path):
2     cap = cv2.VideoCapture (video_path)
3     # ... 初始化模型、ROI 等 ...
4     while True:
5         ret, frame = cap.read()
6         if not ret: break
7         # ... 执行人脸检测、OCR、融合、绘制 ...
8         frame_rgb = cv2.cvtColor (frame, cv2.COLOR_BGR2RGB)
9         yield frame_rgb # 逐帧返回
10    cap.release ()
```

- 前端每次请求新帧时，生成器继续执行直至下一次 yield。
- Gradio 内部处理了生成器的迭代，确保不会阻塞主线程。
- 每帧处理耗时需控制在一定范围内（通常小于帧间隔时间），否则会出现卡顿。代码中通过跳帧（降低 OCR 和人脸检测频率）和缩放图像来优化速度。

10.4 可视化增强与用户体验

前端显示的画面中，后端已绘制了丰富的辅助信息，帮助用户直观理解识别结果：

- **人脸框**：绿色矩形框标注检测到的主播面部。
- **ROI 区域**：红色矩形框显示人脸检测区域；蓝色和黄色矩形框分别标示字幕和弹幕提取区域。
- **情感标签**：画面左上角显示融合后的最终情感（如“Happy (92.3%)”），并实时更新。
- **原始文本**：展示 OCR 识别出的字幕和弹幕内容（截断显示）。
- **单模态置信度**：可选显示视觉和文本分支的置信度，便于调试。

这些信息均由后端绘制后整体返回，前端仅负责展示，保证了界面简洁与渲染效率。

10.5 部署与访问方式

- **本地运行**：执行 python app.py 后，Gradio 会在本地启动一个 Web 服务，默认监听 `http://127.0.0.1:7860`。

11 实验结果与综合分析

11.1 整体实验结果

- **系统完整性**：完整实现视频读取、人脸检测、OCR 文本提取、单模态识别、多模态融合、可视化、前端交互全部功能，程序运行稳定、视频播放无明显卡顿
- **同情感场景**：文本与表情情感一致时，多模态识别结果稳定，置信度高于单模态
- **干扰场景**：光照、遮挡、文字歧义等干扰下，多模态融合抗干扰能力显著强于单模态
- **矛盾场景**：表情与文本情感冲突时，动态加权策略可实现折中决策，输出符合真实直播语境的结果

11.2 各模块运行效果

- **YuNet 人脸检测**：正常画面下人脸检出率高，降级 Haar 检测器后仍可基础使用
- **EasyOCR 离线识别**：清晰字幕、标准弹幕识别准确率高，小字、重叠文字识别效果下降
- **双模型推理**：CPU/GPU 均可正常推理，GPU 环境下帧率明显提升
- **动态融合算法**：权重自适应逻辑生效，无权重卡死、计算异常问题
- **前端交互**：Gradio 界面响应迅速，视频流实时性良好，用户操作直观便捷

12 系统现存问题与后续改进方向

12.1 当前存在的问题（结合代码与实验现象）

- **数据集局限**：文本、视觉模型训练数据集规模较小，直播小众网络用语、特殊表情覆盖不足，泛化能力有限
- **OCR 性能短板**：依赖画面清晰度，弹幕密集、文字倾斜、模糊画面下识别准确率大幅下降；未做文字纠偏处理
- **文本模型能力不足**：自研简化版 Transformer 结构简单，未使用大规模预训练 BERT 权重，复杂语义、反讽语句理解能力弱
- **模态融合层次单一**：仅采用决策层晚期融合，未利用特征层融合，模态深层关联特征未被挖掘
- **模态种类缺失**：当前仅视觉、文本双模态，未利用直播音频（主播语气、观众声音）信息
- **人脸策略**：仅固定全屏 ROI 检测人脸，若主播位置偏移则可能漏检
- **前端功能有限**：当前仅支持视频上传和播放，缺乏进度控制、暂停/继续、结果导出（如 CSV）等高级交互功能

12.2 优化与改进方案

- **数据与模型升级**: 扩充直播弹幕、表情数据集, 增加反讽、谐音、方言类文本样本; 替换离线简易 Transformer, 引入正式预训练 BERT 模型, 提升文本语义理解能力
- **OCR 模块优化**: 增加图像二值化、去噪、倾斜校正等预处理, 接入文字纠错模型, 提升复杂画面文本识别率
- **融合算法升级**: 引入注意力机制, 自动学习不同场景下模态重要性, 替代简单线性加权
- **模态拓展**: 新增语音情感识别模块, 构建视觉 + 文本 + 语音三模态融合系统, 全方位解析直播情感
- **人脸检测优化**: 取消固定 ROI 限制, 增加多人脸筛选、主播身份区分逻辑, 适配主播移动、多人同框场景
- **前端增强**: 添加播放控制条、帧率显示、结果统计图表、一键导出分析报告等功能, 提升用户体验

13 实验总结

本实验基于 Python 与深度学习技术, 结合 YuNet、ResNet18、简易 Transformer、EasyOCR 等工具, 成功搭建一套面向直播场景的双模态情感识别系统, 完整完成题目要求的五大核心任务, 并额外构建了基于 Gradio 的前端交互界面。

系统通过视觉表情识别捕捉主播外在情绪, 通过文本情感识别解读观众弹幕与字幕语义, 再依托动态加权晚期融合策略实现双模态信息互补。前端界面提供视频上传、一键启动、实时画面显示等便捷操作, 使非技术用户也能轻松使用系统。实验证明: 相较于单一视觉或文本模型, 多模态融合方案在准确率、鲁棒性、复杂场景适应性上具备明显优势, 尤其在表情与文本情感矛盾的典型直播场景中, 能够做出更贴合实际语境的判断。

本次实验不仅完成了算法层面的验证, 还落地为工程化可运行代码, 实现了视频实时推理、可视化交互等实用功能, 为直播情感分析、人机情感交互、直播内容风控等后续研究与工程应用提供了可行的实践方案。同时, 本实验也梳理出模型、数据、算法以及前端交互上的不足, 为后续多模态情感识别系统的迭代优化指明了方向。

参考文献

- [1] OpenCV. Face Detection YuNet model. https://github.com/opencv/opencv_zoo
- [2] He K, Zhang X, Ren S, et al. Deep residual learning for image recognition[C]. Proceedings of the IEEE conference on computer vision and pattern recognition, 2016: 770-778.
- [3] Vaswani A, Shazeer N, Parmar N, et al. Attention is all you need[C]. Advances in neural information processing systems, 2017: 5998-6008.
- [4] Jaided AI. EasyOCR: Ready-to-use OCR with 80+ supported languages. <https://github.com/JaidedAI/EasyOCR>
- [5] Gradio. Build and share delightful machine learning apps. <https://gradio.app>